UNIVERSIDADE FEDERAL DA PARAÍBA
CENTRO DE INFORMÁTICA
CURSO DE CIÊNCIA DE DADOS E INTELIGÊNCIA ARTIFICIAL

MICAEL OLIVEIRA DE LIMA TOSCANO
SÉRGIO CAUÃ DOS SANTOS

CLASSIFICAÇÃO DE DESEMPENHO E ABSENTEÍSMO NO ENEM: UMA ABORDAGEM POR MACHINE LEARNING COM BASE NOS FATORES SOCIOECONÔMICOS DOS PARTICIPANTES

JOÃO PESSOA
2026

MICAEL OLIVEIRA DE LIMA TOSCANO
SÉRGIO CAUÃ DOS SANTOS

CLASSIFICAÇÃO DE DESEMPENHO E ABSENTEÍSMO NO ENEM: UMA ABORDAGEM POR MACHINE LEARNING COM BASE NOS FATORES SOCIOECONÔMICOS DOS PARTICIPANTES

Relatório Final de Pesquisa apresentado ao Curso de Bacharelado em Ciência de Dados e Inteligência Artificial da Universidade Federal da Paraíba como requisito parcial para a conclusão da disciplina de Aprendizagem de Máquina.

JOÃO PESSOA
2026

MICAEL OLIVEIRA DE LIMA TOSCANO
SÉRGIO CAUÃ DOS SANTOS

CLASSIFICAÇÃO DE DESEMPENHO E ABSENTEÍSMO NO ENEM: UMA ABORDAGEM POR MACHINE LEARNING COM BASE NOS FATORES SOCIOECONÔMICOS DOS PARTICIPANTES

Relatório de Pesquisa apresentado ao Curso de Bacharelado em Ciência de Dados e Inteligência Artificial da Universidade Federal da Paraíba como requisito parcial para a conclusão da disciplina Aprendizagem de Máquina.

Aprovado em: __/__/2026.

_____

Coordenação do Curso de Bacharelado em Ciência de Dados e Inteligência Artificial

Considerações:

_____

_____

_____

_____

_____

_____

_____

_____

_____

_____

CLASSIFICAÇÃO DE DESEMPENHO E ABSENTEÍSMO NO ENEM: UMA ABORDAGEM POR MACHINE LEARNING COM BASE NOS FATORES SOCIOECONÔMICOS DOS PARTICIPANTES

RESUMO: Esse estudo analisa a influência de fatores socioeconômicos no desempenho e no absenteísmo dos participantes do Exame Nacional do Ensino Médio (ENEM) entre os anos de 2019 e 2023. A pesquisa caracteriza-se como um estudo analítico quantitativo baseado em técnicas de aprendizado de máquina para a identificação de padrões de desigualdade social que refletem na educação. Utiliza microdados do Instituto Nacional de Estudos e Pesquisas Educacionais Anísio Teixeira (INEP) processados e refinados para os algoritmos *Decision Tree*, *Random Forest*, *Support Vector Machine* (SVM) e Redes Neurais. Técnicas como *One Hot Encoding*, *Ordinal Encoding*, validação cruzada e *Stratified K-Fold* foram utilizadas a fim de garantir uma boa generalização dos modelos. Os resultados indicam que as Redes Neurais são mais robustas na classificação de desempenho, alcançando uma acurácia de 71%, enquanto modelos baseados em árvores são superiores na predição de presença do aluno e na interpretabilidade das variáveis.

Palavras-chave: Aprendizagem de Máquina. Desempenho. ENEM. Presença.

CLASSIFYING PERFORMANCE AND ABSENTEEISM IN ENEM: A MACHINE LEARNING APPROACH BASED ON PARTICIPANT'S SOCIOECONOMIC FACTORS

ABSTRACT: This study analyzes the influence of socioeconomic factors on the performance and absenteeism of participants in the *Exame Nacional do Ensino Médio* (ENEM) between 2019 and 2023. The research is characterized as a quantitative analytical study based on machine learning techniques for identifying patterns of social inequality reflected in education. Microdata from the *Instituto Nacional de Estudos e Pesquisas Educacionais Anísio Teixeira* (INEP) were processed and refined for use with the Decision Tree, Random Forest, Support Vector Machine (SVM), and Neural Network algorithms. Techniques such as One-Hot Encoding, Ordinal Encoding, cross-validation, and Stratified K-Fold were applied to ensure adequate model generalization. Results indicate that Neural Networks are more robust in performance classification, achieving an accuracy of 71%, while tree-based models outperform in predicting student attendance and in the interpretability of variables.

Keywords: Attendance. ENEM. Machine Learning. Performance.

AGRADECIMENTOS

Agradecemos, primeiramente, ao Prof. Dr. Bruno Jefferson de Sousa Pessoa e ao Prof. Dr. Gilberto Farias de Souza Filho, ambos do Centro de Informática da Universidade Federal da Paraíba (UFPB).

LISTA DE FIGURAS/IMAGENS

Figura 1 - 18

LISTA DE TABELAS/QUADROS

Tabela 1 – Resultado dos modelos treinados com os anos de 2019 a 2023 para classificar o desempenho do aluno ..……..... 15
Tabela 2 – Resultado dos modelos treinados com os anos de 2019 a 2023 para classificar a presença do aluno 15
Tabela 3 – Resultado dos modelos treinados com os anos de 2019 a 2022 e testado com 2023 para classificar o desempenho do aluno 16
Tabela 4 – Resultado dos modelos treinados com os anos de 2019 a 2022 e testado com 2023 para classificar a presença do aluno 17

LISTA DE ABREVIATURAS E SIGLAS

UFPB - Universidade Federal da Paraíba
SVM - Support Vector Machine
ENEM - Exame nacional do Ensino Médio
INEP - Instituto Nacional de Estudos e Pesquisas Educacionais Anísio Teixeira

SUMÁRIO

1 IDENTIFICAÇÃO **9**
2 INTRODUÇÃO **9**
3 OBJETIVOS **10**
3.1 OBJETIVO GERAL 10
3.2 OBJETIVOS ESPECÍFICOS 10
4 PLANEJAMENTO DO EXPERIMENTO **11**
4.1 TEMA E PROBLEMA DE PESQUISA 11
4.2 HIPÓTESES 12
4.3 JUSTIFICATIVA 12
5 MATERIAIS E MÉTODOS **13**
6 RESULTADOS **15**
7 DISCUSSÃO **18**
8 CONCLUSÃO **19**
REFERÊNCIAS **19**

1 IDENTIFICAÇÃO

Título do Projeto: Classificação de Desempenho e Absenteísmo no ENEM: Uma Abordagem por Machine Learning com Base nos Fatores Socioeconômicos dos Participantes

Nome dos Autores: Micael Oliveira de Lima Toscano, Sérgio Cauã dos Santos

Nome dos Orientadores: Bruno Jefferson de Sousa Pessoa, Gilberto Farias de Sousa Filho

Local de execução: Centro de Informática (CI) – Universidade Federal da Paraíba (UFPB), João Pessoa - PB.

Vigência do plano de trabalho: 2025.2

2 INTRODUÇÃO

O Exame Nacional do Ensino Médio (ENEM) é o meio principal de ingresso na maioria das universidades brasileiras, o qual, em tese, funciona como um indicador para avaliar a qualidade do ensino médio e o aprendizado do aluno. Em contradição, tem-se que as desigualdades socioeconômicas encontradas no Brasil influenciam diretamente no desempenho dos estudantes, sendo fatores como renda familiar, escolaridade dos pais e contexto social, variáveis relevantes, para explicar diferenças nas notas obtidas nessa prova.

Na tentativa de subverter essa problemática, foram desenvolvidas, e ainda estão sendo, leis como a Lei de Cotas, que visa garantir 50% das vagas dos cursos de ensino superior nas universidades federais para estudantes de escolas públicas. Entre essas vagas, há uma separação para outras minorias, como: estudantes de famílias com renda per capita de até 1.5 salário mínimo; pessoas pretas, pardas ou indígenas; e pessoas com alguma deficiência. Apesar desses avanços, ainda persistem diferenças significativas no desempenho e na participação dos estudantes no exame, evidenciando a necessidade de estudos que permitam compreender melhor esses padrões.

Nesse contexto, torna-se interessante a possibilidade de classificar alunos em risco antes mesmo da aplicação da prova, utilizando informações socioeconômicas. Essa abordagem preventiva pode permitir que órgãos governamentais identifiquem

estudantes que necessitam de apoio adicional, aumentando as chances de participação e de desempenho no ENEM.

Desse modo, este relatório faz um estudo baseado nos microdados do ENEM dos anos entre 2019 a 2023, disponibilizados pelo INEP, com o objetivo de identificar se os fatores socioeconômicos, tais como: renda familiar, patrimônio familiar, estado civil, tipo de escola que frequentou e entre outros; conseguem conter informações suficientes para que seja possível fazer uma classificação não só de desempenho, como também de presença no dia da prova.

Para isso, foram usados modelos de aprendizagem de máquina tais como: Decision Tree, Random Forest, SVM e Redes Neurais, que fornecem um alto valor para classificação e permitem a identificação de padrões. Essa abordagem possibilita não apenas classificar o desempenho dos participantes com base em suas características socioeconômicas, como também avaliar a importância de cada fator na explicação das diferenças observadas.

Como resultado, foi possível identificar o modelo com a melhor capacidade de generalização para os dois problemas analisados, permitindo a construção de uma pipeline de inferência que utiliza as probabilidades estimadas pelos classificadores para gerar uma análise mais interpretável do perfil do participante. Além disso, a probabilidade estimada para bom desempenho acabou sendo utilizada como um escore contínuo para estimar a chance de entrada do aluno em diferentes áreas de cursos de ensino superior.

3 OBJETIVOS

3.1 OBJETIVO GERAL

Analisar a influência de fatores socioeconômicos no desempenho e no comparecimento dos participantes do ENEM por meio da aplicação de técnicas de Machine Learning, com o objetivo de identificar padrões preditivos e avaliar a relevância dessas variáveis na explicação das desigualdades educacionais observadas.

3.2 OBJETIVOS ESPECÍFICOS

a) Aplicar os modelos de Machine Learning: Decision Tree, Random Forest, Support Vector Machine (SVM) e Redes Neurais para classificar o desempenho dos estudantes com base em seus dados socioeconômicos;
b) Desenvolver os modelos para estimar a probabilidade de comparecimento dos participantes nos dias de aplicação do ENEM;
c) Realizar o ajuste de hiperparâmetros dos modelos, utilizando técnicas de validação cruzada, visando melhorar a capacidade de generalização;
d) Construir uma pipeline de inferência baseada nas probabilidades estimadas pelos modelos para geração de perfis de risco educacional dos participantes;
e)Utilizar as probabilidades previstas de desempenho como um escore para estimar a chance relativa de ingresso em diferentes áreas de curso de ensino superior;

4 PLANEJAMENTO DO EXPERIMENTO

4.1 TEMA E PROBLEMA DE PESQUISA

O ENEM, enquanto um estimador de qualidade do ensino médio no Brasil, deve ser um objeto de estudo cada vez mais abordado, visto que o desempenho dos alunos nele reflete a realidade em que a educação se encontra. Nesse sentido, observa-se que os fatores socioeconômicos são grandes agravantes da disparidade entre os estudantes que prestam essa prova, dado que variáveis como renda familiar, tipo de escola, nível de escolaridade dos pais, faixa etária e condições sociais mostram-se determinantes para explicar parte das diferenças observadas nas notas dos candidatos.

Apesar da existência de políticas públicas voltadas à democratização do acesso ao ensino superior, ainda persistem diferenças significativas no desempenho entre estudantes de diferentes contextos sociais. Além disso, observa-se que muitos estudos focam apenas em análises estatísticas descritivas, havendo espaço para outras abordagens, como o uso de técnicas de Machine Learning, que permitem identificar padrões complexos e realizar previsões baseadas em grandes volumes de dados educacionais.

Dessa forma, torna-se relevante investigar não apenas se os dados socioeconômicos presentes nos microdados do INEP conseguem expressar o

desempenho dos estudantes, como também, se é possível analisar a probabilidade de participação no exame a partir dessas características.

Assim, esse trabalho busca responder ao seguinte problema de pesquisa: Em que medida variáveis socioeconômicas permitem a construção de modelos capazes de classificar o desempenho e a presença dos participantes do ENEM?

4.2 HIPÓTESES

a) Estudantes que se encontram em uma condição social mais elevada, como maior renda familiar, maior escolaridade dos pais e acesso a escolas privadas, tendem a apresentar melhor desempenho nas provas do ENEM quando comparados a estudantes em situação de maior vulnerabilidade social;

b) Existe relação entre os fatores socioeconômicos dos participantes e a probabilidade de abstenção no ENEM, sendo que estudantes em condições sociais mais desfavoráveis apresentam maior tendência à ausência no exame;

c) Modelos de Machine Learning treinados com variáveis socioeconômicas são capazes de identificar padrões relevantes e apresentar desempenho preditivo significativo na classificação de desempenho e presença dos participantes;

4.3 JUSTIFICATIVA

A abordagem dos microdados do ENEM por meio das técnicas de Aprendizado de Máquina é fundamental, pois possibilita extrair padrões de comportamento a partir de grandes volumes de dados educacionais, os quais muitas vezes não são capturados por alguns métodos estatísticos tradicionais. Dessa forma, o uso dessas técnicas contribui para uma análise mais profunda acerca dos fatores que influenciam o desempenho dos estudantes e sua participação no exame.

No contexto deste projeto, a aplicação prática dessas técnicas é exemplificada pelo pipeline desenvolvido, que combina modelos de classificação para prever tanto a presença quanto o desempenho dos alunos. Essa pipeline

permite identificar perfis individuais, como “vai e performa bem” ou “alto risco geral”, e quantificar probabilidades de presença e desempenho acima ou abaixo da mediana. Assim, a análise não se limita a tendências gerais, mas oferece informações sobre cada estudante, possibilitando intervenções educacionais mais direcionadas.

Dessa forma, o uso de Machine Learning no estudo dos micro dados socioeconômicos do ENEM contribui não apenas para o avanço acadêmico, permitindo novas formas de análise de dados educacionais, como também para auxiliar na classificação de estudantes que se encontram em situação de vulnerabilidade antes mesmo da aplicação da prova.

5 MATERIAIS E MÉTODOS

A pesquisa teve início com a definição do problema de estudo e dos objetivos da análise, seguida pela coleta dos microdados do ENEM disponibilizados pelo Instituto Nacional de Estudos e Pesquisas Educacionais Anísio Teixeira (INEP).

Devido ao grande volume de dados, foi necessário realizar uma etapa de engenharia nos dados para otimizar o processamento e leitura dos arquivos. Os dados, originalmente, disponibilizados no formato .csv foram convertidos para o formato .parquet, que possui melhor desempenho em operações de leitura e escrita por ser um tipo de armazenamento colunar, além de permitir uma compressão mais eficiente das informações.

Cada modelo de Aprendizado de Máquina possui requisitos específicos quanto à representação dos dados, tornando necessário um tratamento diferenciado das variáveis para garantir um melhor desempenho dos algoritmos. Para os modelos SVM e Redes Neurais foi aplicado One Hot Encoding que consiste em quantificar variáveis categóricas em uma representação binária, incluindo as respostas do questionário socioeconômico, enquanto as variáveis ordinais foram transformadas utilizando o Ordinal Encoder, de modo a preservar a relação de ordem existente entre as categorias.

Nos modelos baseados em árvores, Random Forest e Decision Tree, também foi utilizado One Hot Encoding nas variáveis categóricas do questionário socioeconômico, juntamente com agregações em algumas dessas variáveis com o objetivo de aumentar a relevância informacional dos atributos.

Para todos os modelos, foi criada a variável FALTOU, utilizada tanto como critério para filtrar apenas os alunos presentes em todas as provas no problema de classificação de desempenho, quanto como variável alvo no problema de classificação de presença. Essa variável foi construída a partir dos indicadores de presença nas quatro áreas do exame, sendo classificado como ausente o participante que faltou a pelo menos uma delas.

Além disso, foram removidas as colunas de raça e sexo para evitar discriminação direta na saída do modelo e realizado o tratamento de valores ausentes nas variáveis TP_LOCALIZACAO_ESC, TP_DEPENDENCIA_ADM_ESC e TP_SIT_FUNC_ESC, substituindo os valores nulos por zero. Essa decisão foi tomada considerando que participantes já concluintes do Ensino Médio não possuem vínculo escolar ativo no momento da inscrição, o que justifica a ausência dessas informações. Esse procedimento evita a perda desnecessária de dados e permite que os modelos utilizem essas informações sem introduzir viés causado pela remoção de observações.

Durante a fase de preparação dos modelos, foram adotadas duas abordagens de divisão. Na primeira abordagem, todos os anos foram utilizados para treino e teste, seguindo uma proporção padrão de 80% para treino e 20% para teste, em seguida foram separados 20% dos dados de treino para validação, com o objetivo de garantir uma avaliação melhor da capacidade de generalização dos algoritmos. Já na segunda abordagem, os anos de 2019 a 2022 foram utilizados para treino e validação e 2023 para teste. O conjunto de treino foi utilizado para o ajuste dos modelos, o conjunto de validação para a escolha dos melhores hiperparâmetros e o conjunto de teste se manteve intocável até o final do treinamento para ser um bom estimador para dados não vistos. Também foi utilizada a técnica de validação cruzada durante o processo de treinamento, reduzindo o viés introduzido pela escolha aleatória da porção dos dados de validação a partir dos dados de treino, que por consequência reduz ainda mais o risco de overfitting.

Com os resultados obtidos pelos modelos, foram selecionados aqueles que apresentaram o melhor desempenho nos problemas de classificação de presença e de desempenho. Esses modelos foram integrados em uma pipeline de inferência, desenvolvida com o objetivo de simular a predição do perfil de um aluno com base em suas características socioeconômicas.

Essa pipeline recebe os dados de um participante, reproduz o mesmo pré-processamento aplicado durante o treinamento dos modelos e retorna as probabilidades estimadas de presença no exame e de desempenho acima ou abaixo da mediana. A partir dessas probabilidades, foi criada uma categorização interpretável dos perfis dos estudantes, como por exemplo: alunos com boa probabilidade de presença e bom desempenho e alunos com necessidade de apoio acadêmico.

Por fim, a probabilidade estimada de bom desempenho também foi utilizada como um escore contínuo para estimar as chances hipotéticas de ingresso em diferentes áreas de cursos do ensino superior, permitindo uma interpretação mais aplicada dos resultados obtidos pelos modelos.

6 RESULTADOS

Tabela 1 – Resultado dos modelos treinados com os anos de 2019 a 2023 para classificar o desempenho do aluno

Modelo	Precisão	Recall	F1-Score	Acurácia
Decision Tree	0,69	0,69	0,69	0,69
Random Forest	0,70	0,70	0,70	0,70
Rede Neural	**0,71**	**0,71**	**0,71**	**0,71**
SVM	0,69	0,69	0,69	0,69

Fonte: elaborado pelos autores (2026)

Tabela 2 – Resultado dos modelos treinados com os anos de 2019 a 2023 para classificar a presença do aluno

Modelo	Precisão	Recall	F1-Score	Acurácia
Decision Tree	**0,64**	**0,65**	**0,64**	**0,64**
Random Forest	**0,64**	**0,65**	**0,64**	**0,64**
Rede Neural	0,61	0,64	0,60	0,63
SVM	0,61	0,63	0,57	0,58

Fonte: elaborado pelos autores (2026)

Tabela 3 – Resultado dos modelos treinados com os anos de 2019 a 2022 e testado com 2023 para classificar o desempenho do aluno

Modelo	Precisão	Recall	F1-Score	Acurácia
Decision Tree	0,69	0,69	0,68	0,68
Random Forest	0,69	0,69	0,69	0,69

Rede Neural	**0,70**	**0,70**	**0,69**	**0,69**
SVM	**0,70**	**0,70**	**0,69**	**0,69**

Fonte: elaborado pelos autores (2026)

Tabela 4 – Resultado dos modelos treinados com os anos de 2019 a 2022 e testado com 2023 para classificar a presença do aluno

Modelo	Precisão	Recall	F1-Score	Acurácia
Decision Tree	0,63	0,64	0,63	0,66
Random Forest	**0,63**	**0,65**	**0,63**	**0,66**
Rede Neural	0,61	0,60	0,60	0,71
SVM	0,60	0,63	0,56	0,58

Fonte: elaborado pelos autores (2026)

Figura 1 – Exibição da Decision Tree para a Classificação de presença no ENEM

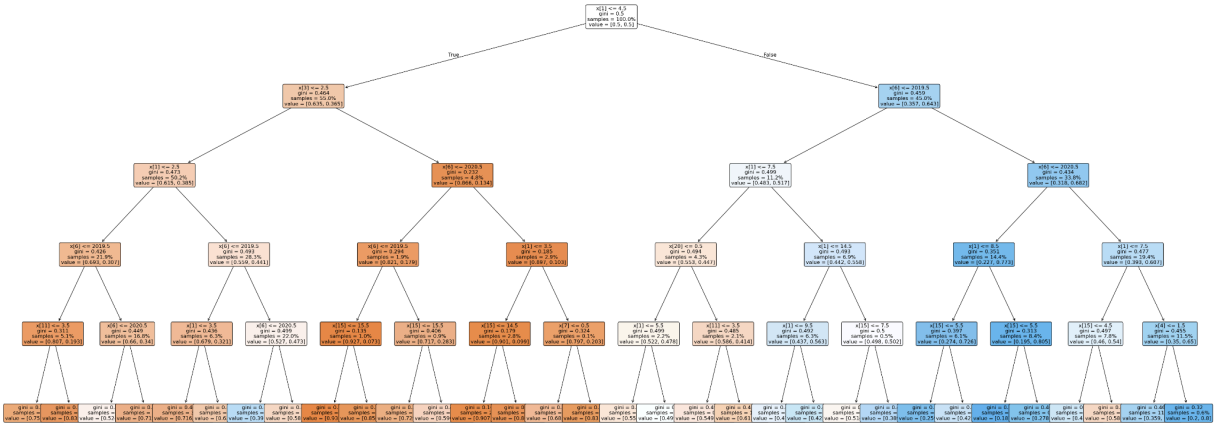

Fonte: elaborado pelos autores (2026)

7 DISCUSSÃO

O estudo teve como objetivo classificar o desempenho e prever se o aluno irá ao dia do exame com base nos seus dados socioeconômicos. Com a obtenção dos resultados do modelo, observa-se que no cenário de classificar o desempenho com uma amostra de todos os anos, a rede neural se mostra mais robusta, sendo 2% melhor do que modelos de árvores e SVM. Quando o ano de 2023 é separado para teste, o modelo de Rede Neural e SVM empatam em todas as métricas (recall, precisão, f1-score e acurácia).

Já na predição da presença do aluno, modelos de árvores no geral desempenham melhor. Para a estratégia de treinar com todos os anos, a Decision Tree e o Random Forest tiveram aproximadamente 6% de melhora em relação ao SVM, enquanto que para a Rede Neural a diferença foi de apenas 1%. No caso em que o ano de 2023 foi usado para teste, optou-se por utilizar o modelo de Random Forest que maximiza o recall, pois o custo de não identificar um aluno que está em risco de ausência é mais prejudicial do que classificar de forma equivocada um aluno presente como faltante. Além disso, os resultados dos testes realizados, sugerem um limite de aprendizagem dado as features que o modelo tinha disponível para ser treinado. Colunas como raça e sexo foram removidas por motivos éticos e para não introduzir viés sociais aos dados.

A escolha do modelo Decision Tree se dá ao fato de ser um modelo altamente interpretável, diferente das redes neurais que operam em uma “caixa-preta”. Quando os nós da árvore estão pintados na cor laranja, significa que o modelo tem mais amostras de estudantes da classe 0 do que da classe 1, ou seja, de ter seu

desempenho abaixo da média. Por outro lado, quando os nós estão pintados de azul, o modelo tem mais amostras de alunos classe 1 que representam os acima da média. Nos nós de cor branca, há um balanceamento de classe 0 e 1, o modelo apresenta alto nível de incerteza, pois não conseguiu encontrar uma variável que separe bem aqueles dados.

8 CONCLUSÃO

Conclui-se, portanto, que o questionário socioeconômico possui uma base de informações valiosa e capaz de predizer, com margem significativa (70% aproximadamente de acurácia) o comportamento dos estudantes no exame. Ao utilizar modelos como Redes Neurais e SVM, apesar de serem modelos com alta capacidade de se ajustar e encontrar padrões nos dados, há uma limitação na interpretabilidade da sua saída. Modelos como Decision Tree, entrega as features e o caminho que o aluno passou nos filtros até ser classificado como da classe 1 ou da classe 0. Apesar de não ter tido a melhor das acurácias em todos os testes, esse modelo se mostra valioso como classificador primário. Isso ocorre porque, em um contexto de criação de políticas públicas, compreender o motivo do aluno ser classificado como “em risco” é crucial para a tomada de decisão e definir prioridades de onde atacar o problema social.

As variáveis socioeconômicas explicam bem o padrão dos dados, mas não são os únicos fatores determinantes. Embora a renda e a escolaridade dos pais, por exemplo, criem uma base sólida de oportunidades (ou a falta delas), outras questões psicológicas, logísticas, qualidades específicas de ensino nas escolas públicas e privadas e até motivação pessoal, também são fatores determinantes no dia do exame.

REFERÊNCIAS

INSTITUTO NACIONAL DE ESTUDOS E PESQUISAS EDUCACIONAIS ANÍSIO TEIXEIRA (INEP). **Microdados do Exame Nacional do Ensino Médio – ENEM**. Disponível em: https://www.gov.br/inep/pt-br/acesso-a-informacao/dados-abertos/microdados/enem. Acesso em: 14 mar. 2026.

KERAS. Keras API reference. Disponível em: https://keras.io/api/. Acesso em: 28 mar. 2026.

MATPLOTLIB. Matplotlib documentation. Disponível em: https://matplotlib.org/stable/index.html. Acesso em: 28 mar. 2026.

NUMPY. NumPy documentation. Disponível em: https://numpy.org/doc/. Acesso em: 28 mar. 2026.

PANDAS. Pandas documentation. Disponível em: https://pandas.pydata.org/. Acesso em: 16 mar. 2026.

SCIKIT-LEARN. Scikit-learn User Guide. Disponível em: https://scikit-learn.org/stable/user_guide.html. Acesso em: 28 mar. 2026.